Titulo do artigo

Maria Clara de Souza Aquino[1], **Maria Clara da Silva Ferreira**[1]

[1] Universidade Federal Rural de Pernambuco
Engenharia da Computação

{,mariaclara.ferreira}@ufrpe.br

Abstract. *test*

Resumo. *Teste*

1. Metodologia

Este trabalho replica o *baseline* do *benchmark* de Silveira et al. [3] e o estende em duas direções: (i) a avaliação em uma base de dados diferente, o EssayBR, e (ii) a avaliação com um grande modelo de linguagem (LLM). Em todos os casos, a tarefa é prever, para cada redação, as notas das cinco competências do ENEM (0, 40, 80, 120, 160 ou 200 pontos); a nota total, de 0 a 1000, é a soma das cinco.

1.1. Bases de dados

AES-ENEM. Usamos a Fonte A do AES-ENEM com notas de avaliadores, composta por 395 redações de 41 temas, coletadas do Educação UOL [3]. Cada redação tem até três anotações: a nota original do site e as de dois avaliadores especialistas. Cada anotação é tratada como uma instância, o que resulta em 1.165 instâncias, divididas em treino (758), validação (198) e teste (209), com temas distintos em cada divisão.

EssayBR. É a versão estendida do corpus Essay-Br [1], com 6.577 redações de 151 temas, cada uma com uma única nota por competência e a nota total. Usamos a versão com o texto já limpo. Como o Essay-Br e a Fonte A foram coletados dos mesmos *sites*, as bases compartilham redações: 383 (5,8%) das redações do EssayBR também estão no AES-ENEM. Elas foram identificadas por coincidência de trechos de 8 palavras (mais de 30% do texto) e removidas da avaliação, restando 6.194 redações.

Nas duas bases, a nota de cada competência é convertida em uma classe ordinal de 0 a 5 (nota dividida por 40) e o texto é truncado em 512 *tokens*.

1.2. Modelos

BERTimbau com regressão ordinal. Replicamos o modelo ordinal do artigo original: o BERTimbau base [4] com a função de perda CORN [2], treinando um modelo independente para cada competência. A representação do *token* [CLS] passa por *dropout* (0,2) e por uma camada linear de 5 saídas, correspondentes às 6 classes. O ajuste fino usa o treino da Fonte A, com AdamW (taxa de aprendizado 3×10^{-5}, *weight decay* 0,01, lotes de 8), no máximo 15 épocas e parada antecipada pela perda de validação (paciência 2), com semente 42. Esses hiperparâmetros foram definidos por nós e podem diferir dos do artigo original. O modelo é treinado apenas no AES-ENEM e aplicado ao EssayBR sem nenhum ajuste.

LLM. Avaliamos **[NOME E VERSÃO DA LLM]** sem ajuste fino. A LLM recebe apenas o texto da redação, como o BERTimbau, pois o EssayBR não traz o enunciado dos temas. Um *prompt* descreve as cinco competências do ENEM e pede, para cada uma, uma nota entre 0, 40, 80, 120, 160 e 200, em formato estruturado. **[Definir: *zero-shot* ou *few-shot*, temperatura e data das execuções.]**

1.3. Protocolo de avaliação

Os dois modelos são avaliados nos mesmos conjuntos: (i) o teste da Fonte A (209 instâncias), para a replicação e a comparação com o artigo original, e (ii) o EssayBR sem as redações repetidas (6.194), para medir a generalização para outra base. As métricas são o *Quadratic Weighted Kappa* (QWK), o erro quadrático médio (RMSE, em pontos) e a divergência, que é o percentual de redações em que a nota prevista difere da humana em mais de 80 pontos nas competências e em mais de 100 pontos na nota total, como no artigo original. Como a dispersão das notas difere entre as bases, o RMSE também é comparado ao de um preditor que sempre responde a nota média. As métricas são calculadas sobre o conjunto completo de teste; o subconjunto sem divergência entre anotadores, reportado no artigo original, não é usado aqui.

Referências

[1] Jeziel Marinho, Rafael Anchîeta, and Raimundo Moura. Essay-BR: a Brazilian corpus to automatic essay scoring task. *Journal of Information and Data Management*, pages 65–76, 2022.

[2] Xintong Shi, Wenzhi Cao, and Sebastian Raschka. Deep neural networks for rank-consistent ordinal regression based on conditional probabilities, 2021. arXiv preprint.

[3] Igor Cataneo Silveira, André Barbosa, and Denis Deratani Mauá. A new benchmark for automatic essay scoring in Portuguese. In Pablo Gamallo, Daniela Claro, António Teixeira, Livy Real, Marcos Garcia, Hugo Gonçalo Oliveira, and Raquel Amaro, editors, *Proceedings of the 16th International Conference on Computational Processing of Portuguese - Vol. 1*, pages 228–237, Santiago de Compostela, Galicia/Spain, March 2024. Association for Computational Lingustics.

[4] Fábio Souza, Rodrigo Nogueira, and Roberto Lotufo. BERTimbau: pretrained BERT models for Brazilian Portuguese. In *Proceedings of the 9th Brazilian Conference on Intelligent Systems (BRACIS)*, pages 403–417, 2020.